

英文短信垃圾信息识别

阶段 1 报告：问题界定与计算原型

项目 / 阶段	英文短信垃圾信息识别 / 阶段 1
队名 / 成员	队名待填写；成员：杨俊炜、赵煜凡
日期 / 版本	2026-09-26 / phase-1-submission-v3（本地标签）
仓库地址	暂留空；创建远程仓库后补充 URL

执行摘要

本项目拟开发一个供个人用户复核英文短信的垃圾信息识别工具。阶段 1 将问题限定为单条纯文本短信的二分类，明确输入验证、输出解释与人工复核边界，并完成无需外部依赖的 Python 命令行原型。原型依据中奖、领取、催促和链接等线索给出规则分数，附带触发原因；14 个自动化测试已通过。自行编写的演示短信仅用于检查程序行为，不能证明真实分类性能。下一阶段将引入 UCI SMS Spam Collection，检查来源、重复与类别分布，建立固定划分和基线评估，再比较学习方法。当前主要风险是英文语料与实际短信之间的分布差异，以及规则误判和规避。

1. 问题定义与范围

现实问题：用户收到陌生短信时，需要快速识别值得重点检查的可疑内容。目标用户是对英文短信进行初步筛查的个人；最终处置仍由用户决定。系统任务是单条文本分类，而不是判断发信人身份或验证链接安全性。

项目要素	阶段 1 定义
输入	一条 1 - 1000 字符的英文纯文本短信；不接受空白或明显中文输入。
输出	spam / ham 标签、非概率的整数规则分数、触发的规则名。
范围边界	只给出复核建议；不读取私人收件箱，不自动拦截/删除，不处理附件、图片或多语言。

可衡量的最终目标（预先设定，尚未达成）：在冻结的独立测试集上，垃圾短信召回率不低于 0.90，正常短信误拦率不高于 0.05；报告精确率与混淆矩阵。阶段 1 的完成标准是可重复运行、至少 8 个有意义测试通过。

2. 动机与相关工作

垃圾短信筛查同时面对漏检与误拦：漏检会让用户继续接触可疑内容；误拦可能妨碍正常沟通。因此后续评估必须同时观察垃圾短信召回率与正常短信误拦率，而不能只看总体准确率。

资料	本项目的借鉴与边界
[1] UCI SMS Spam Collection	公开英文短信标签语料，页面列出 5,574 条记录与 CC BY 4.0 许可。适合作为后续数据来源；数据来源混合，不能代表所有语言或当前短信流量。
[2] Almeida 等, 2011	介绍短信垃圾过滤语料与研究结果，为问题与数据背景提供依据。本项目不直接沿用其结果数值。
[3] scikit-learn 文本分类教程	示范文本向量化、朴素贝叶斯与流水线。后续阶段将据此实现学习方法，并与本阶段规则基线在同一划分上比较。

2.1 项目差距与学习目标

现成教程可以演示分类器，却不能代替本课程要求的任务定义、数据泄漏检查、受控比较、端到端系统和失败分析。本项目的学习目标是把这些环节连成可复现的证据链，并明确何时只能建议人工复核。

3. 计算建模

组件	输入与输出 / 职责
输入验证	str → 合法短信或明确异常；限制原始长度、空白、明显不支持的文字。
文本归一化	短信 → NFKC、大小写折叠、空白折叠后的文本；保持确定性。
规则评分	归一化文本 → 触发规则集合与整数分数；每条规则最多计一次。
决策与输出	分数达到 3 → spam, 否则 ham；返回标签、分数和规则名称。

3.1 数据结构与流程

数据结构：输入为 Python 字符串；输出为不可变的 `Classification(label: str, score: int, signals: tuple[str, ...])`。处理流程：输入 → 校验 → 归一化 → 规则匹配/加权 → 阈值判断 → 命令行呈现。每个模块只处理一项职责，便于后续把规则模块替换为学习模型。

假设：当前演示输入主要是英文纯文本。规则数量固定为 6，每条规则至多扫描一次短信，因此对长度为 n 的短信，粗略运行成本为 $O(6n)$ ，即随文本长度近似线性增长；这只是代码结构分析，不是实测延迟。

4. Python 原型与可检查输出

原型位于 `sms_filter/rules.py`，命令行入口位于 `sms_filter/__main__.py`。它不训练模型；所有规则和阈值公开且可修改。分数是规则加权和，不代表“垃圾概率”。

匹配线索	权重	设计理由
中奖/奖品词	2	较强可疑线索，但单独出现不足以判定。
领取要求、免费/现金/奖励、立即拨打、网址	各 1	弱线索组合后触发，避免一个普通链接直接导致误拦。
紧急/限时措辞	2	与其他线索结合后触发。

4.1 可复现的示例运行

输入（自行编写）	实际输出	说明
You won a prize. Claim it now!	spam, 分数 3	中奖词 2 + 领取要求 1。
Are you free for lunch tomorrow?	ham, 分数 1	仅含 free，不足阈值。
恭喜中奖	明确报错	明显中文文本超出原型支持范围。

运行命令：`python -m sms_filter --text "You won a prize. Claim it now!"`。演示数据保存在 `data/demo_messages.jsonl`；它由项目编写，不参与真实性能评估。

4.2 自动化测试

使用 Python 标准库 `unittest` 执行 `python -m unittest discover -s tests -v`，结果为 14/14 通过。测试覆盖明显垃圾信息、普通对话、大小写、全角字符归一化、词边界、正常句中的 free、单独链接、规则解释、空白输入、非字符串、超长输入、中文、纯数字和重复运行的确定性。

观察	证据能支持什么	证据不能支持什么
14 个测试通过	约定的规则行为与边界处理在当前环境正确。	无法推出真实短信的召回率、误拦率或跨领域效果。
4 条合成演示短信	命令行能接受代表性输入并产生可检查输出。	不能当作独立测试集，也不能据此调阈值后报告性能。

4.3 已知失败与异常

“Urgent cash needed for taxi”会触发紧急词与 cash，可能将正常求助误判为 spam；“Claim your package at https://...”可能因分数不足而漏检。两者是人为构造的风险示例，不是来自真实数据的错误率估计。

5. 可行性、资源与风险

资源	当前状态 / 后续动作
软件与运行环境	阶段 1 仅 Python 3.10+ 标准库；README 给出运行和测试命令。阶段 2-3 计划固定 scikit-learn 等依赖版本。
数据	阶段 1 使用自行编写的合成演示文本；阶段 2 再下载 UCI 英文短信语料，记录来源、许可、类别、重复和字段。
时间与人员	成员：杨俊炜、赵煜凡；各阶段具体分工与截止日期待填写。

5.1 主要风险与应对

风险	影响	计划中的处理
误拦正常短信	用户可能错过消息。	优先报告正常短信误拦率；输出仅供人工复核，不自动删除。
漏检与词形规避	可疑短信仍被当作普通短信。	阶段 3 比较学习模型；阶段 5 做拼写扰动压力测试。
数据偏差/年代差	公开英文语料与当前、本地短信不同。	限制外推结论，记录数据收集背景；另做分布偏移测试。
重复文本泄漏	训练与测试共享近似短信导致虚高。	阶段 2 先检查重复与近重复，再冻结划分；仅在训练集拟合同量器。
隐私与许可证	真实短信可能包含个人信息。	不收集私人短信；使用公开许可数据，标注来源和 AI 协助。

6. 阶段 2-5 里程碑

阶段	具体任务	完成标准
2 数据与实验	核对语料、数据字典、去重、固定划分、EDA、规则基线。	能复现主要图表与召回率/误拦率；划分和泄漏检查有记录。
3 比较建模	同一数据划分下比较规则、词袋+朴素贝叶斯、TF-IDF+逻辑回归。	统一指标、重复试验、至少一项消融和错误分类。
4 系统集成	封装所选模型，提供 CLI 或简单 Web 界面、输入验证与日志。	正常、困难、拒绝/错误三类端到端演示及集成测试。
5 扩展与综合	针对阶段 3-4 暴露的问题做字符级特征或弃权机制等扩展。	固定数据上做前后受控比较、鲁棒性审计、成本与部署计划。

7. 下一阶段执行计划

任务	责任人	依赖与完成标准
下载和核验语料	待填写	记录来源、许可、文件校验值；核对记录数和标签。
探索与数据字典	待填写	统计类别、长度、缺失与重复；至少一项发现改变后续设计。
划分与防泄漏	待填写	先处理重复，再固定训练/验证/测试划分和随机种子。
规则基线评估	待填写	报告垃圾召回率、正常误拦率、精确率、混淆矩阵和错误案例。
复现与报告	待填写	一条命令重建主要结果；提交阶段 2 PDF 与对应标签。

依赖关系：先完成许可和数据核验，再冻结划分，然后才计算基线结果；不得根据测试集表现回调规则或阈值。团队确认后填写实际责任人和日期。

8. 局限性与个人贡献

本阶段没有使用 UCI 真实数据，也没有训练机器学习模型，因此不报告准确率、召回率或任何“AI 优于基线”的结论。规则只处理英文纯文本，并以有限词汇捕捉可疑线索。后续阶段需要验证这些规则是否值得保留。

成员：杨俊伟、赵煜凡。队名与每人的实际贡献待填写；最终提交前，应写明各自完成的代码、实验和报告部分，并能解释所提交的内容。

生成式 AI 披露：阶段 1 的选题整理、代码与报告初稿由生成式 AI 协助形成；提交者应逐项运行、复核和修改，并对结论负责。本阶段未调用外部模型或付费 API，未使用外部代码复制。

9. 参考资料

[1] Almeida, T. 与 Hidalgo, J. UCI Machine Learning Repository: SMS Spam Collection.
<https://archive.ics.uci.edu/dataset/228/sms+spam+collection> , 访问日期: 2026-09-26。

[2] Almeida, T. A., Hidalgo, J. M. G., & Yamakami, A. (2011). Contributions to the study of SMS spam filtering: New collection and results. ACM DocEng. DOI: 10.1145/2034691.2034742.

[3] scikit-learn developers. Working with text data.
https://scikit-learn.org/stable/tutorial/text_analytics/working_with_text_data.html , 访问日期: 2026-09-26。

[4] scikit-learn developers. Classification metrics API.
<https://scikit-learn.org/stable/api/sklearn.metrics.html> , 访问日期: 2026-09-26。

附：可复现性与反馈记录

仓库应含 README、源码、数据样例、依赖说明及 14 个测试。修订版使用本地标签 phase-1-submission-v3 固定提交版本；远程仓库 URL 待建立。教师的第一轮反馈尚未收到，反馈回复表将在阶段 2 增补。