

英文短信垃圾信息识别

阶段 2 报告：数据与实验设计

项目 / 阶段	英文短信垃圾信息识别 / 阶段 2
队名 / 成员	队名待填写；成员：杨俊炜、赵煜凡
日期 / 版本	2026-09-26 / phase-2-submission-v2（本地标签）
仓库地址	暂留空；远程仓库建立后填写 URL

执行摘要

阶段 2 使用 UCI SMS Spam Collection 的 5,574 条已标注英文短信，核验许可、压缩包校验值、标签和文本完整性，并完成数据字典与探索分析。语料中垃圾短信占 13.4%，按归一化文本发现 415 条重复行；因此采用按文本分组的固定划分，并以召回率和正常短信误拦率作为关键指标。第一阶段规则及阈值保持不变，只在验证集评估：按独特文本计，识别出 17/96 条垃圾短信，正常短信误拦 0/677，另有 1 条不支持的输入。结果显示规则漏检明显，测试集保留给后续模型研究。主要局限是语料来源混合、年代较早，且没有可验证的用户级与时间信息。

1. 问题表述与本阶段变化

目标用户仍是需要人工复核英文短信的个人。输入是一条英文纯文本短信；输出是 spam/ham 标签、非概率规则分数和触发原因。系统只给出复核建议，不自动删除。阶段 1 预设的最终目标为独立测试集垃圾短信召回率至少 0.90、正常短信误拦率至多 0.05；这两个值是目标，不是本阶段结果。

本阶段依据真实数据修订实验设计：因为类别不平衡，总体准确率不足以概括效果；因为存在重复文本，先分组再划分；因为原型拒绝明显中文文本，评估同时报告覆盖率。第一阶段的规则和阈值 3 未改动。

2. 数据来源与许可

数据来自 UCI Machine Learning Repository 的 SMS Spam Collection [1]，原始压缩包按 SHA-256 固定：1587ea43e58e82b14ff1f5425c88e17f8496bfcd67a583dbff9eefaf9963ce3。数据页标注 CC BY 4.0 许可。公开页面说明正常与垃圾短信由多个来源合并，文本未按时间排序；因此结果不自动代表当前短信流量。原始文本可能含电话号码，仓库只保存下载程序与行号划分清单，不再分发短信全文。

3. 数据集描述与质量核验

字段	类型与含义	处理方式
row_id	原文件行号，从 1 开始；观察单位为一条短信。	仅用于追踪和冻结划分，不作模型特征。
label	ham（正常）或 spam（垃圾）；分类目标。	验证限定取值；后续保持二分类定义。
text	UTF-8 原始短信文本，可能含网址或号码。	不展示未脱敏内容；训练变换仅拟合训练集。
派生字段	长度、显式网址标记、归一化文本分组键。	仅用于探索与防泄漏；不修改原文本。

3.1 类别与完整性

图 1 原始短信标签数量（单位：条）



图 1 显示正常短信 4,827 条、垃圾短信 747 条。标签或文本缺失 0；归一化后独特文本 5,159，重复行 415，重复组的标签冲突 0。压缩包共 5,574 行且 UTF-8 可完整解码。以上只是结构核验，无法证明每条标签语义均正确。

3.2 与任务相关的分布

图 2 按标签的短信长度中位数（单位：字符）



垃圾短信长度中位数为 149 字符，正常短信为 52；90 分位数分别为 160 与 147 字符。显式网址分别出现在垃圾短信 106/747 条、正常短信 2/4827 条。该网址检测只认 http(s):// 或 www.，不能覆盖所有链接。

改变设计的观察：类别比例不均，使“总准确率”容易掩盖漏检；重复文本要求分组划分；网址分布差异可能部分反映语料来源，而非可直接泛化的垃圾信息规律。

4. 数据处理流水线与防泄漏

步骤	实现与验证
获取与固定	tools/fetch_uci_data.py 从 UCI 官方地址下载压缩包；与固定 SHA-256 比对，变化时拒绝静默替换。
解析与验证	sms_filter/dataset.py 逐行 UTF-8 解码，按首个制表符拆出标签和文本；未知标签或空文本立即报错。
保留与派生	保留原始文本；NFKC、大小写和空白归一化仅用于精确重复分组，不删除数字、标点或网址。
固定划分	每个标签内部按归一化文本组排序后用种子 42 洗牌，约 70/15/15 分到训练、验证、测试。
泄漏检查	原始行号只出现一次；三个集合的归一化文本组两两不交。后续词表、TF-IDF 等只在训练集拟合。

4.1 冻结的划分结果

集合	短信行数	正常	垃圾	独特文本组	用途
训练	3880	3363	517	3611	拟合未来学习模型
验证	831	716	115	774	本阶段基线与后续选择
测试	863	748	115	774	阶段 3 后的一次性评估

注：比例按独特文本组分配，同组的重复行必须进入同一集合，因此实际行数并非严格 70/15/15。短信没有可靠时间戳或用户标识，无法进行时序或用户级独立划分；这限制了外部有效性。

4.2 可复现性与数据访问

执行 `python -m tools.fetch_uci_data`、`python -m tools.run_phase2` 可重建汇总表、划分清单及验证结果。`artifacts/split_manifest.json` 只含源行号、种子与源文件校验值；`data/dataset_card.md` 记录字段、来源、许可和风险。原始压缩包位于 Git 忽略的 `data/raw/`。

阶段 2 检查了完全相同或仅有全角、大小写、空白差异的文本；拼写替换、号码改写等近重复仍可能跨集合。后续应做近重复敏感性分析，不能把“无精确重复跨集合”解释为完全没有相似文本泄漏。

5. 规则基线与评估方案

基线是阶段 1 已固定的六类人工规则，分数达到 3 判为 spam，其余判为 ham。它不使用训练数据，也未根据验证或测试结果调阈值。主要指标是垃圾短信召回率 $TP/(TP+FN)$ ，反映漏检；次要指标为正常短信误拦率 $FP/(FP+TN)$ 、垃圾短信精确率与覆盖率，反映误拦和弃权。

5.1 验证集结果：以独特文本组为单位

实际标签 / 预测	spam	ham	弃权
垃圾 spam	17	79	0
正常 ham	0	677	1

基于 774 个独特文本组，覆盖 773 个（99.9%）。垃圾召回率 $17/96 = 17.7\%$ ，95% Wilson 区间 11.4% - 26.5%；正常误拦率 $0/677 = 0.0\%$ ，区间 0.0% - 0.6%。精确率为 100%，但仅基于 17 个被识别的垃圾文本，不能解释为稳定的完美表现。[3]

5.2 按原始行加权的敏感性结果

验证集有 831 行，规则覆盖 830 行。按行计 $TP=26$ 、 $FN=89$ 、 $FP=0$ 、 $TN=715$ ，垃圾召回率 22.6%，正常误拦率 0.0%。独特文本组召回率更低，提示重复短信会改变汇总指标；因此以独特文本组结果作为本阶段的主要比较依据。

5.3 错误与不确定性

验证集按行有 89 条垃圾短信漏检，其中 50 条连一条规则都未触发；86 条包含数字，但数字本身不能证明其为垃圾信息。另有 1 条含汉字的正常短信被明确弃权。结果支持在阶段 3 比较词袋及字符级表示，但不证明任何一种表示必然改善效果。

Wilson 区间以独特文本组近似作为观察单位，仍未消除共同语料来源和相似表达造成的相关性。零误拦只表示本验证样本的观察值；独立测试集尚未用于性能报告。

6. 数据风险、伦理与适用边界

问题	本阶段判断与处理
来源与选择偏差	正常/垃圾信息由不同早期语料组合，语言、年代和采集方式不一致；不声称当前用户表现。
标签与敏感信息	标签质量尚未逐条人工复核；原始短信可能含电话和私人内容，仓库不重新分发原文。
假正例/假反例	误拦可能影响正常沟通，漏检会留下风险；界面应提供复核而非自动删除。
公平性与滥用	没有可靠的人口属性，不能做群体公平性结论；只研究防护性筛查，不生成攻击短信。

7. 下一阶段计划

任务	责任人	完成标准
模型对比	待填写	同一冻结划分比较规则、词袋+朴素贝叶斯、TF-IDF+逻辑回归。
受控实验	待填写	仅训练集拟合特征；验证集选择；记录种子、配置、耗时和至少一项消融。
错误分析	待填写	按短信长度、网址、拼写变体检查失败与模型分歧，不展示未脱敏文本。
最终测试	待填写	方法冻结后才在测试集运行一次，报告模型及系统约束下的选择理由。

8. 复现、贡献与反馈

本阶段可运行命令和环境见 README；核心处理只需 Python 3.10+ 标准库，报告生成脚本使用 ReportLab 与 Windows SimHei 字体。自动化测试共 22 个且全部通过。成员为杨俊炜、赵煜凡；队名、真实个人贡献和远程仓库 URL 暂留空；本地修订版使用 phase-2-submission-v2 标签。

生成式 AI 披露：阶段 2 代码、分析和报告草稿由生成式 AI 协助完成，提交者需复核并能解释。教师对阶段 1 的反馈尚未提供，故反馈回复表暂记“未收到”，取得反馈后应增补修改及证据位置。

参考资料

[1] Almeida, T. & Hidalgo, J. (2011). SMS Spam Collection. UCI Machine Learning Repository. <https://archive.ics.uci.edu/dataset/228/sms+spam+collection> , 访问日期: 2026-09-26。

[2] Almeida, T. A., Hidalgo, J. M. G., & Yamakami, A. (2011). Contributions to the study of SMS spam filtering: New collection and results. ACM DocEng. DOI: 10.1145/2034691.2034742。

[3] NIST/SEMATECH. Confidence intervals for a binomial proportion (Wilson method). <https://itl.nist.gov/div898/handbook/prc/section2/prc241.htm> , 访问日期: 2026-09-26。